

Escuela de Ciencia de la Computación

Examen Final

CC531 A Análisis en Macrodatos 2026-1


Parte 1 [6 pts.]:

Resolver en el laboratorio de clase 6 preguntas de teoría de forma individual, en hoja y con lapicero.

Parte 2 [14 pts]:

Se pide configurar y programar un Clúster de Spark con HDFS, para ello reutilizar o reinstalar las máquinas virtuales de forma que se pueda usar el HDFS del cluster hadoop, de esta forma en el master este el NodeName de HDFS y el Máster Spark y en los nodos los Data Nodes y Spark Workers. Seguir los manuales en el aula virtual de la semana 15.

Desplegar la siguiente arquitectura:



Realizar:

- Implementar un Cluster de Spark con HDFS multimodo 1 maestro y 2 o más esclavos, en máquinas virtuales mínima de Ubuntu usando virtual box u otro virtualizador a su criterio.
- Elaborar un informe en el cual:
 - Adicional a las secciones de siempre, crear una sección inicial de implementación donde se describirá a grandes rasgos los pasos seguidos.
 - Adjuntando las capturas de pantalla de cada paso de configuración.
- Implementar o usar su VM de un nodo para que comparen rendimientos en los trabajos realizados.
- Buscar un Dataset de la Plataforma Nacional de Datos Abiertos (PNDA) que no haya sido expuesto en ninguna de las evaluaciones anteriores (base de datos) relacionado a **Economía y Finanzas**.
- Tanto en el informe como en la presentación:
 - Referenciar la base de datos usada.
 - Referencias investigaciones anteriores realizadas a la base datos.

- Indicar la fuente de dataset y la fecha de publicación, se tomará en cuenta las bases de datos más recientes.
- Referenciar artículos que usaron su dataset si lo hubiera hecho.
- **A partir del Dataset descargado, generar al menos 2 tablas y guardarlas en formato JSON (para que no sea necesario usar postgres).**
- Consultas de spark
 - **Activar el HDFS para que los datos sean jalados desde allí por los programas de spark**
 - **Hacer 2 consultas: la primera usando Sql Spark que tenga group by y las funciones de org.apache.spark.sql.functions, la segunda usando vistas temporales usando OrderBy combinado con otros operadores de selección.**
 - **Hacer 2 consultas con campos decimales que implique el uso de regresión Multilayer perceptrón y otro basado en máquinas de soporte vectorial SVM. Si no hubiera por defecto en la librería ML derivarlo o crearlo.**
 - **Hacer 2 consultas con campos decimales que implique una clasificación Random Forest y Multilayer perceptrón. Si no hubiera por defecto en la librería ML derivarlo o crearlo.**
- Correr su código en el clúster implementado y en su versión de un solo nodo (El que implementaron para la PC4).
- **Implementar una tabla de comparación que mida: Los tiempos de ejecución, el speedup, uso promedio de CPU y memoria. Explicar la razón de las salidas.**
- **Generar una tabla donde comparen las siguientes métricas: Accuracy, Precisión, Recall, F1-score para el caso de modelos de clasificación.**
- **Generar una tabla donde comparen las siguientes métricas: RMSE, MSE, MAE, R² para el caso de modelos de regresión.**
- **Generar una tabla donde comparen el conjunto de métricas de clasificación y regresión en el cluster comparado con un nodo, para cada modelo.**
- **Elaborar los gráficos de perdida de entrenamiento.**
- Adicionar en el informe la imagen del monitor de recursos de la ejecución en paralelo (ejemplo htop) de memoria, de cada procesador, y tiempos de ejecución de cada caso de los nodos en la red, para observar el paralelismo de los procesos.
- Adjuntar los archivos con extensión. scala.
- Adjuntar los inputs y outputs que pudiera tener sus consultas.
- Presentar el Informe y su Presentación. **Recordar que para facilidad de lectura tanto en informe y presentación mencionar claramente el item de pregunta al cual corresponde de la siguiente manera:**
 - Especificar el tipo de pregunta o grupo de pregunta. Mencionar la consulta en el Dataset a la cual responde. Ejem: "Cual es el promedio de marcas usadas..." Explicar la solución e interpretación de los resultados de cada consulta y como dan acceso a la respuesta, indicando las columnas, filas o características que se usan para ello y las partes importantes del código.
- **Durante la exposición se debe mostrar la ejecución del clúster implementado distribuido y el de un solo nodo.**

Observaciones importantes:

- Tomar como base las prácticas de clase y las versiones de spark y hadoop usadas en clase.
- Utilizar las plantillas adjuntas de informe y presentación.
- Los grupos serán de 3 personas a lo sumo.
- Esta prohibido que dos o más grupos utilicen el mismo dataset incluso con rango de fechas o sub partes diferentes, de presentarse el caso no se evaluará a ningún de los grupos involucrados.
- El tiempo limite de exposición es de 12 minutos, de pasarse ese tiempo o hacer bulla o distracción en el aula se aplicarán descuento de puntos.
- Todos los entregables deben presentarse como máximo hasta la fecha establecida en el aula virtual. No se darán plazo adicional de entrega. –
- De no presentarse todo entregable calificado como obligatorio, dado que son componentes básicos para demostrar el trabajo realizado, no se evaluará dicho trabajo o se colocará un puntaje en base a lo que pueda ser verificado.

Entregables:

- Códigos spark con la extensión. scala y sus salidas (Obligatorio)
- Informe y presentación (Obligatorio)
- Archivos json generados para las consultas sql (obligatorio)
- Muestreo en clase **EN VIVO** de la ejecución del cluster (obligatorio)
- Gráficos de perdidas generados
- Dataset usado.

Tabla de puntajes

Item	Objetivo	Hasta...
Informe de implementación	Informe bien explicado de las partes solicitadas resaltando la implementación del cluster y las consultas	2
Prueba en clase multimodo	Prueba en vivo satisfactoria multimodo de spark de una consulta	2
Prueba en clase monomodo	Prueba en vivo satisfactoria monomodo de spark de una consulta	1
Consultas SQL	Consultas sql sobre el json generado	1
Consultas Spark ML	Modelos de ml pedidos implementados satisfactoriamente y probados	2
Tabla de tiempo speedup y memoria comparativa	Tabla comparativa de las métricas de rendimiento entre el monomodo y el cluster	2
Tabla de métricas ML comparativa	Tabla comparativo de las métricas de ML entre el monomodo y cluster	2
Presentacion	Exposición y elaboración de una pesentación	2